



UNIVERSIDADE FEDERAL DO AGRESTE DE PERNAMBUCO

Bacharelado em Ciência da Computação

Estudo Dirigido – Inteligência Artificial 2026.1 – Prof. Dr. Luis Filipe

1 Objetivo

Investigar experimentalmente o funcionamento de classificadores Bayesianos a partir da modelagem probabilística das características de uma base de dados real. O estudo deverá permitir responder, entre outras, às seguintes questões:

- Como uma distribuição de probabilidade pode representar o comportamento de uma característica dentro de uma classe?
- Como diferentes valores observados alteram a evidência em favor de cada classe?
- Qual a diferença entre verossimilhança e probabilidade a posteriori?
- Como as probabilidades a priori das classes influenciam uma decisão Bayesiana?
- Como podemos combinar evidências provenientes de diferentes características?
- Quais erros são cometidos pelo classificador e como eles podem ser identificados por meio de uma matriz de confusão?

2 Organização e acompanhamento

A atividade será realizada em duplas, sob a forma de estudo dirigido. Cada dupla deverá desenvolver o estudo com autonomia, seguindo este roteiro e os conceitos discutidos durante a disciplina.

O acompanhamento das atividades ocorrerá predominantemente de forma assíncrona, por meio de interações realizadas no ambiente virtual da disciplina. Os estudantes poderão apresentar resultados parciais, dúvidas sobre a modelagem probabilística e dificuldades encontradas durante a implementação. Para participar do estudo dirigido, a dupla deverá:

- acompanhar as orientações e os materiais disponibilizados;
- registrar no ambiente virtual da disciplina, até o dia 02/09/2026, os avanços parciais do desenvolvimento e as dúvidas iniciais relacionadas à escolha da base, das características e da modelagem probabilística;
- disponibilizar ao final o código utilizado e o vídeo de apresentação do estudo.

3 Escolha da base de dados

Cada dupla deverá selecionar uma base pública destinada a um problema de **classificação supervisionada**. A base poderá ser obtida, por exemplo, nos repositórios:

- UCI Machine Learning Repository: <https://archive.ics.uci.edu/>;
- Kaggle: <https://www.kaggle.com/datasets>.

A dupla deverá identificar claramente:

- qual é a variável alvo Y ;
- quais são as classes possíveis;
- quais são as características/atributos disponíveis. Quais são numéricas e quais são categóricas.
- o número de observações da base;
- a distribuição das observações entre as classes.

A dupla deverá selecionar exatamente **três características**:

$$X_1, \quad X_2, \quad X_3.$$

Entre as três características escolhidas deverá existir **obrigatoriamente pelo menos uma característica/atributo contínua/numéricas e pelo menos uma característica/atributo categórica**.

Por exemplo:

- X_1 : característica/atributo contínua;
- X_2 : característica/atributo contínua;
- X_3 : característica/atributo categórica.

ou

- X_1 : característica/atributo contínua;
- X_2 : característica/atributo categórica;
- X_3 : característica/atributo categórica.

4 Experimentos com características isoladas

Cada uma das três características

$$X_1, \quad X_2, \quad X_3$$

deverá ser analisada **separadamente** seguindo todas as etapas descritas nesta seção. Portanto, o procedimento deverá ser executado três vezes:

$$X_1 \rightarrow \text{análise Bayesiana},$$

$$X_2 \rightarrow \text{análise Bayesiana},$$

$$X_3 \rightarrow \text{análise Bayesiana}.$$

4.1 Etapa 1 – Hipótese sobre a distribuição

Para cada classe, a dupla deverá propor uma distribuição probabilística capaz de representar a característica. De forma geral:

$$X_j \mid Y = c \sim \mathcal{D}(\theta_{jc}),$$

em que $\mathcal{D}$ representa uma família de distribuições e θ_{jc} seus parâmetros. Para características contínuas, poderão ser consideradas, entre outras, distribuições como:

$$\text{Normal}, \quad \text{Exponencial}, \quad \text{Gamma}.$$

Por exemplo:

$$X_j \mid Y = 0 \sim \mathcal{N}(\mu_0, \sigma_0^2),$$

$$X_j \mid Y = 1 \sim \mathcal{N}(\mu_1, \sigma_1^2).$$

Para características categóricas binárias poderá ser utilizada a distribuição Bernoulli:

$$X_j \mid Y = c \sim \text{Bernoulli}(p_c).$$

Para características com mais de duas categorias deverá ser considerada uma distribuição discreta, estimando-se:

$$P(X_j = a_k \mid Y = c)$$

para cada categoria a_k .

A hipótese escolhida deverá ser **justificada a partir de algum conhecimento consensual sobre o domínio do problema**.

4.2 Etapa 2 – Verossimilhança das observações

Após estimar os parâmetros das distribuições, a dupla deverá investigar como diferentes observações são explicadas por cada classe. Para uma característica contínua, deverão ser comparadas as densidades

$$p(x \mid Y = 0)$$

e

$$p(x \mid Y = 1).$$

Para uma característica categórica, deverão ser comparadas as probabilidades

$$P(X_j = a_k \mid Y = 0)$$

e

$$P(X_j = a_k \mid Y = 1).$$

A dupla deverá identificar regiões e valores em que uma observação é **mais compatível** com uma classe e regiões e valores em que ela é **mais compatível** com a outra.

4.3 Etapa 3 – Razão de verossimilhanças

Para cada característica deverá ser calculada a razão de verossimilhanças:

$$\Lambda(x) = \frac{p(x \mid Y = 1)}{p(x \mid Y = 0)}.$$

A interpretação deverá considerar:

$$\Lambda(x) > 1$$

como evidência fornecida pela característica em favor da classe $Y = 1$,

$$\Lambda(x) < 1$$

como evidência em favor da classe $Y = 0$, e

$$\Lambda(x) = 1$$

como uma situação em que a observação possui a mesma verossimilhança nas duas classes.

Para características categóricas, a razão deverá ser calculada para cada categoria observada. A dupla deverá então responder:

- Para quais valores ou categorias a característica/atributo fornece evidência em favor da classe $Y = 0$?
- Para quais valores ou categorias a característica/atributo fornece evidência em favor da classe $Y = 1$?
- Existem valores para os quais a característica praticamente não fornece informação para distinguir as classes?

4.4 Etapa 4 – Aplicação do Teorema de Bayes

A frequência das classes no conjunto de treinamento deverá inicialmente ser utilizada para estimar:

$$P(Y = 0)$$

e

$$P(Y = 1).$$

Em seguida, para diferentes valores da característica, a dupla deverá calcular as probabilidades a posteriori:

$$P(Y = c | x) = \frac{p(x | Y = c)P(Y = c)}{p(x)} = \frac{p(x | Y = c)P(Y = c)}{\sum_k p(x | Y = k)P(Y = k)}.$$

A dupla deverá apresentar exemplos numéricos completos para cada uma das três características. Em pelo menos um exemplo deverá ser discutida explicitamente a diferença entre:

$$p(x | Y = c),$$

que representa a verossimilhança da observação sob determinada classe, e

$$P(Y = c | x),$$

que representa a probabilidade da classe após considerar a observação.

4.5 Etapa 5 – Regra e fronteira de decisão Bayesiana

Para cada característica contínua, a dupla deverá determinar a regra de decisão induzida pelo classificador Bayesiano. Uma fronteira de decisão ocorre quando:

$$P(Y = 0 | x) = P(Y = 1 | x).$$

Utilizando o Teorema de Bayes, esta condição pode ser escrita como:

$$p(x | Y = 0)P(Y = 0) = p(x | Y = 1)P(Y = 1).$$

A dupla deverá representar graficamente:

- as distribuições condicionais das duas classes;
- a região associada à decisão $Y = 0$;
- a região associada à decisão $Y = 1$;
- a fronteira ou as fronteiras de decisão encontradas.

Para características categóricas, não existe necessariamente uma fronteira contínua. Nesse caso, a dupla deverá apresentar a **regra de decisão associada a cada categoria**. Por exemplo:

$$X_j = a_1 \rightarrow Y = 0,$$

$$X_j = a_2 \rightarrow Y = 1.$$

Ao final desta etapa deverão existir três classificadores Bayesianos univariados:

$$h_1(X_1), \quad h_2(X_2), \quad h_3(X_3).$$

a dupla deverá comparar qualitativamente as três características e discutir qual delas aparentemente possui maior capacidade de discriminação entre as classes.

5 Classificação utilizando as três características

Após realizar as análises anteriores de forma isolada, a dupla deverá considerar simultaneamente as três características:

$$\mathbf{x} = (x_1, x_2, x_3).$$

O objetivo aqui será construir um classificador **Naive Bayes**.

5.1 Hipótese de independência condicional

O Naive Bayes assume que as características são condicionalmente independentes quando a classe é conhecida:

$$p(x_1, x_2, x_3 \mid Y = c) \approx p(x_1 \mid Y = c)p(x_2 \mid Y = c)p(x_3 \mid Y = c).$$

Utilizando o Teorema de Bayes:

$$P(Y = c \mid x_1, x_2, x_3) \propto P(Y = c) \prod_{j=1}^3 p(x_j \mid Y = c).$$

A decisão será dada por:

$$\hat{y} = \arg \max_c \left[P(Y = c) \prod_{j=1}^3 p(x_j \mid Y = c) \right].$$

Para evitar problemas numéricos causados pela multiplicação de probabilidades muito pequenas, você pode implementar a decisão no domínio logarítmico:

$$\hat{y} = \arg \max_c \left[\log P(Y = c) + \sum_{j=1}^3 \log p(x_j \mid Y = c) \right].$$

5.2 Combinação de atributos contínuos e categóricos

O classificador deverá utilizar as mesmas distribuições definidas durante os experimentos individuais. Assim, uma única observação poderá, por exemplo, possuir:

$$x_1 \in \mathbb{R}, \quad x_2 \in \mathbb{R}, \quad x_3 \in \{a_1, a_2, \dots, a_K\}.$$

Nesse caso:

$$p(\mathbf{x} \mid Y = c) = p(x_1 \mid Y = c)p(x_2 \mid Y = c)P(X_3 = x_3 \mid Y = c).$$

Portanto, distribuições contínuas e categóricas deverão ser combinadas dentro de um mesmo classificador. Caso alguma categoria apresente frequência zero no conjunto de treinamento para determinada classe, a dupla deverá investigar e explicar o problema da **probabilidade zero**. Poderá ser utilizada suavização de Laplace quando necessário.

5.3 Implementação

O classificador deverá ser implementado pela própria dupla a partir das equações apresentadas neste documento. A dupla deverá ser capaz de explicar:

- como foram estimadas as probabilidades das classes;
- como foram estimados os parâmetros das distribuições contínuas;
- como foram estimadas as probabilidades das variáveis categóricas;
- como as três evidências são combinadas;
- como é obtida a decisão final.

6 Separação entre treinamento e teste

A base deverá ser dividida em conjuntos de treinamento e teste. Todos os parâmetros das distribuições

$$p(X_j \mid Y = c)$$

e todas as probabilidades a priori

$$P(Y = c)$$

deverão ser estimados utilizando **exclusivamente o conjunto de treinamento**. O conjunto de teste deverá ser utilizado somente para avaliar o classificador final. A dupla deverá informar claramente:

- a proporção utilizada para treinamento e teste;
- o número de observações em cada conjunto;
- o desbalanceamento entre classes observado no treinamento e teste;
- a semente aleatória utilizada na divisão.

7 Avaliação utilizando matriz de confusão

O resultado final do classificador Naive Bayes deverá ser apresentado utilizando uma **matriz de confusão**. A matriz de confusão compara a classe verdadeira de cada observação com a classe prevista pelo classificador. Para um problema binário:

	Predito: 0	Predito: 1
Real: 0	VN	FP
Real: 1	FN	VP

em que:

- **VP – Verdadeiro Positivo:** a observação pertence à classe positiva e foi corretamente classificada como positiva;
- **VN – Verdadeiro Negativo:** a observação pertence à classe negativa e foi corretamente classificada como negativa;
- **FP – Falso Positivo:** a observação pertence à classe negativa, mas foi classificada como positiva;
- **FN – Falso Negativo:** a observação pertence à classe positiva, mas foi classificada como negativa.

A matriz de confusão permite observar não apenas quantas classificações foram corretas, mas também **quais tipos de erro foram cometidos pelo modelo**. A dupla deverá apresentar a matriz de confusão obtida sobre o conjunto de teste e interpretar seus quatro componentes. Além da matriz, deverão ser calculadas:

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN},$$

$$\text{Precisão} = \frac{VP}{VP + FP},$$

$$\text{Recall} = \frac{VP}{VP + FN},$$

e

$$F_1 = 2 \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}.$$

Para problemas com **três ou mais classes**, a matriz de confusão é generalizada para uma matriz $K \times K$, em que K representa o número de classes. Cada linha corresponde à classe verdadeira e cada coluna à classe predita pelo classificador. Os elementos da diagonal principal representam as classificações corretas, enquanto os elementos fora da diagonal indicam confusões entre diferentes classes. Assim, a matriz permite identificar não apenas quantos erros foram cometidos, mas também **quais classes são mais frequentemente confundidas entre si**. Para calcular precisão, recall e F_1 em problemas multiclasse, cada classe pode ser analisada individualmente como positiva em relação às demais (*one-vs-rest*), sendo posteriormente possível calcular médias como *macro*, *micro* ou ponderada.

8 Resultados que deverão ser apresentados

Ao final do estudo, deverão ser apresentados pelo menos os seguintes resultados:

1. descrição da base de dados e do problema de classificação;
2. distribuição das classes;
3. identificação e descrição das três características escolhidas;
4. indicação de quais características são contínuas e quais são categóricas;
5. para cada uma das três características, visualização de seu comportamento separadamente para cada classe;
6. hipótese de distribuição probabilística adotada para cada característica;
7. parâmetros estimados das distribuições;
8. comparação das verossimilhanças das classes para diferentes observações;
9. cálculo e interpretação da razão de verossimilhanças;
10. cálculo de probabilidades a posteriori utilizando o Teorema de Bayes;
11. regra ou fronteira de decisão obtida para cada característica isoladamente;
12. implementação do classificador Naive Bayes utilizando simultaneamente as três características;
13. matriz de confusão obtida no conjunto de teste;
14. interpretação dos falsos positivos e falsos negativos;
15. acurácia, precisão, recall e F_1 ;
16. discussão das limitações da modelagem probabilística adotada.

9 Entrega

A entrega deverá conter:

- link para vídeo apresentado pelos dois integrantes da dupla;
- link para repositório GitHub contendo todo o código utilizado;
- arquivo `README.md` com instruções claras para instalação e execução;
- arquivo `requirements.txt` contendo as dependências necessárias;
- identificação e link para a base de dados utilizada.

O código deverá permitir a reprodução das análises e dos resultados apresentados no vídeo.

10 Conteúdo obrigatório do vídeo

O vídeo, de até **15 minutos**, deverá assumir o formato de uma **conversa técnica entre os dois integrantes da dupla**. Ambos deverão participar das explicações e demonstrar conhecimento sobre todo o estudo.

A apresentação deverá explicar:

1. o problema de classificação escolhido e a origem da base de dados;
2. a variável alvo e o significado das classes;
3. as três características escolhidas e a justificativa para sua escolha;
4. quais características são contínuas e quais são categóricas;
5. o comportamento observado de cada característica dentro de cada classe;
6. as distribuições probabilísticas escolhidas para representar cada característica e a justificativa dessas escolhas;
7. o significado de $p(x \mid Y = c)$ no contexto do problema;
8. exemplos de cálculo e interpretação das verossimilhanças;
9. o significado e a interpretação da razão de verossimilhanças;
10. a aplicação do Teorema de Bayes para calcular $P(Y = c \mid x)$;
11. a diferença conceitual entre verossimilhança $p(x \mid Y = c)$ e probabilidade a posteriori $P(Y = c \mid x)$;
12. a regra ou fronteira de decisão obtida para cada uma das três características;
13. a hipótese de independência condicional utilizada pelo Naive Bayes;
14. como características contínuas e categóricas foram combinadas no classificador;
15. a implementação da regra de decisão utilizando as três características;
16. a matriz de confusão obtida no conjunto de teste;
17. o significado de verdadeiro positivo, verdadeiro negativo, falso positivo e falso negativo no problema estudado;
18. os principais erros observados e possíveis explicações;
19. as limitações das hipóteses probabilísticas adotadas;
20. o que foi delegado a ferramentas de IA generativa e como o material produzido foi verificado, corrigido e validado.

Não será aceito código produzido por IA que os integrantes não sejam capazes de explicar, testar, modificar e validar.

11 Critérios de avaliação

A avaliação considerará:

- compreensão da teoria Bayesiana;
- adequação das hipóteses probabilísticas adotadas;
- correção da implementação;
- qualidade da análise das três características;
- capacidade de relacionar verossimilhança, prior, posterior e decisão;
- correta implementação e explicação do Naive Bayes;
- qualidade da avaliação experimental;
- interpretação da matriz de confusão;
- capacidade crítica na discussão das hipóteses e limitações do modelo;
- clareza técnica da apresentação;
- reprodutibilidade do experimento.

Um estudo somente será considerado completo quando o código disponibilizado permitir reproduzir os resultados apresentados e ambos os integrantes forem capazes de explicar as decisões de modelagem e implementação.

Data-limite para entrega: 06/07/2026. Pontuação: até 1,0 ponto extra na 2aVA. Forma de envio: Ambiente Virtual Classroom
